

Gruppe A

Ahmad Alkaseb - cph-aa540@stud.ek.dk, Aleksandr Uktamovich Sorokin - also1002@stud.ek.dk, Jeppe Jeppsson - jeje1006@stud.ek.dk, Frederik Nicolajsen - frni1004@stud.ek.dk, Roman Ghazi - rogh1000@stud.ek.dk, Kasper Amin - kaam1000@stud.ek.dk

1. Indledning og problemfelt

Large Language Models (LLMs) bruges i stigende grad til kommunikation, læring, softwareudvikling, videnssøgning og beslutningsstøtte. Det gør interaktionen mellem menneske og model til en vigtig del af systemets kvalitet. En LLM modtager ikke blot data; den fortolker instruktioner, kontekst og formuleringer. Derfor kan uklare prompts, gradvise ændringer i betydning, fabrikerede svar og bevidst manipulation påvirke resultatet, selv når outputtet virker sprogligt overbevisende.

Denne synopsis undersøger tre centrale prompting-artifacts: ambiguity/semantic drift, hallucination og prompt injection. De behandles ikke som tre isolerede problemer, men som dele af en fælles risikokæde: et uklart eller manipuleret input kan påvirke modellens fortolkning; et misvisende output kan derefter påvirke brugerens forståelse; og hvis outputtet anvendes i en organisation eller af en AI-agent, kan fejlen omsættes til beslutninger eller handlinger.

Problemformulering

Hvordan kan ambiguity og semantic drift, hallucination samt prompt injection reducere troværdigheden af LLM-baserede systemer, og hvilke organisatoriske og tekniske tiltag kan begrænse risikoen?

2. Metode og litteraturgrundlag

Arbejdet er et litteraturreview og følger opgavens fokus på analyse og syntese af eksisterende forskning frem for egne eksperimenter. Der anvendes nyere studier og benchmarks om multi-turn samtaler, semantic drift, hallucination detection og prompt injection. Kilderne bruges både til at definere fænomenerne og til at vurdere, hvad resultaterne betyder i en organisatorisk kontekst.

Der er samtidig metodiske begrænsninger. Laban et al. (2025) anvender simulerede samtaler og måler derfor primært modeladfærd under kontrollerede forhold. Maxwell (u.å.) studie af semantic drift anvender en prompt, som eksplicit omformer akademisk materiale til LinkedIn-lignende kommunikation, hvilket betyder, at resultaterne bør bruges som evidens for risikoen ved rekursiv transformation - ikke som bevis for, at samme drift altid opstår. HHEM-resultaterne hos Zhang, Wang og Meng (2026) er opgaveafhængige, og sikkerhedsstudierne af Jaiswal et al. (2026) tester bestemte modeller og angreb. Konklusionerne i denne synopsis er derfor en syntese af mønstre på tværs af kilderne, ikke en påstand om universel fejlrate.

3. Ambiguity og semantic drift

3.1 Fra under specificering til ustabil adfærd

Ambiguity opstår, når en instruktion kan forstås på flere måder, eller når væsentlige krav mangler. I menneskelig samtale er det normalt at uddybe intentionen over flere ture, men Laban et al. (2025) viser, at LLM'er kan være markant mindre pålidelige i netop sådanne multi-turn situationer. I deres eksperimenter faldt gennemsnitlig performance fra cirka 90 % i

fuldt specificerede single-turn instruktioner til cirka 60 % i underspecificerede multi-turn-samtaler. Forskerne beskriver også en gennemsnitlig stigning i unreliability på 112%. Problemet var ikke kun, at modellen 'vidste mindre', men at den oftere tog en forkert retning og havde svært ved at rette kursen. (Laban et al., 2025)

De observerede fejlkilder er relevante for almindelig prompting: modellerne forsøger ofte at give et endeligt svar for tidligt, antager manglende detaljer, bygger videre på tidligere forkerte svar og kan overbetone information fra begyndelsen eller slutningen af en længere samtale. Det betyder, at en bruger kan opleve et svar som sammenhængende, selv om modellen har låst sig fast på en forkert fortolkning. (Laban et al., 2025)

3.2 Semantic drift: når fakta bevares, men formålet ændres

Semantic drift beskriver en gradvis ændring i betydning, formål, målgruppe eller kontekst. Maxwells studie af 500 rekursive outputs fandt kun omkring 1,9-2 % fald i faktisk accuracy fra første til sidste generation, mens den udviklede Purpose Fidelity-måling faldt 42,5 %. Pointen er, at faktisk korrekthed ikke nødvendigvis garanterer, at teksten stadig udfører samme kommunikative funktion. (Maxwell, u.å.)

I en virksomhed kan dette være relevant, når LLM'er bruges til at omskrive krav, opsummere dokumenter, oversætte policies eller videreformidle tekniske beslutninger. Hvis teksten bliver mere poleret, kortere eller mere målrettet, kan centrale forbehold og den oprindelige hensigt samtidig forskydes. Ambiguity og semantic drift er derfor ikke kun sproglige problemer; de kan ændre grundlaget for, hvad mennesker tror systemet eller dokumentet faktisk siger. (Maxwell, u.å.)

4. Hallucination

4.1 Hvad er en hallucination?

HalluLens (Bang et al., 2025) fremhæver, at hallucination og factuality ikke er det samme. Factuality handler om, hvorvidt en påstand er korrekt i forhold til en ekstern sandhedskilde. Hallucination handler derimod om, hvorvidt outputtet er konsistent med den viden eller kontekst, modellen faktisk havde adgang til. Denne skelnen er vigtig, fordi forskellige problemer kræver forskellige løsninger.

Intrinsic hallucination: Outputtet modsiger eller er ikke understøttet af den givne inputkontekst.

Extrinsic hallucination: Modellen producerer indhold, der ikke kan understøttes af dens tilgængelige viden og typisk opstår, når modellen forsøger at udfylde et videnshul.

4.2 Hvorfor er hallucination et samfunds- og organisationsproblem?

Hallucination bliver særligt problematisk, fordi et forkert svar kan være flydende, detaljeret og selvsikkert. Det kan gøre det vanskeligt for en bruger at se forskel på verificeret information og plausible fabrikationer. HalluLens fremhæver derfor konsekvenser for brugerens tillid og downstream decision making. Hvis en hallucination bruges som grundlag for et notat, en beslutning, et kundesvar eller en ny prompt, kan den forkerte oplysning desuden blive videreført. (Bang et al., 2025)

Zhang, Wang og Meng (2026) viser samtidig, at hallucination detection selv er vanskelig. Deres HHEM-baserede løsning nåede 76,9 % accuracy på en QA-opgave, mens en version med ekstra non-fabrication checking nåede 82,2 %. På længere summarization-opgaver var lokale hallucinationer sværere at opdage, fordi et langt svar kan være overvejende korrekt og stadig indeholde enkelte forkerte elementer. Segmentbaseret verifikation forbedrede derfor detektionen. (Zhang, Wang & Meng, 2026)

4.3 Begrænsning af hallucination

Litteraturen peger på flere supplerende tiltag: modellen kan afstå fra at svare, når den er usikker; RAG eller andre eksterne kilder kan tilføre verificerbar information; og output kan kontrolleres i mindre dele frem for kun som én samlet tekst. Ingen af metoderne giver dog en perfekt garanti. Derfor bør graden af verifikation afhænge af konsekvensen ved at tage fejl. (Bang et al., 2025; Zhang, Wang & Meng, 2026)

5. Prompt injection

5.1 Fra forkert svar til bevidst manipulation

Prompt injection adskiller sig fra de to foregående fænomener ved, at påvirkningen kan være bevidst. Et angreb forsøger at få LLM'en til at følge angriberens instruktioner frem for systemets tilsigtede adfærd. Instruktionen kan komme direkte fra brugeren eller være skjult i eksternt indhold, som modellen læser. Risikoen vokser, når LLM'en ikke kun skriver tekst, men fungerer som agent med adgang til filer, e-mail, databaser, API'er eller andre værktøjer.

Jaiswal et al. (2026) evaluerede ti open-source modeller på 91 prompt injection- og 74 jailbreak-scenarier. Studiet viser store forskelle mellem modeller og finder, at letvægtsforsvar kan reducere simple angreb, men at lange og reasoning-heavy prompts fortsat kan omgå flere forsvar. Det betyder, at man ikke bør basere sikkerheden på en antagelse om, at 'den gode systemprompt' alene kan holde modellen på sporet.

5.2 Sikkerhed gennem systemdesign

Beurer-Kellner et al. (2025) skelner mellem LLM-level, user-level og system-level forsvar. Promptfiltre og modelinstruktioner kan hæve barrieren, men er heuristiske og giver ikke garanti. Derfor fremhæves system-level isolation som en mere robust retning: untrusted data må ikke frit kunne ændre agentens control flow eller udløse konsekvensfulde handlinger.

To illustrative design patterns er Action-Selector og Plan-Then-Execute. I Action-Selector må agenten kun vælge mellem på forhånd definerede handlinger. I Plan-Then-Execute fastlægges planen, før agenten behandler potentielt manipuleret tredjepartsdata. Sammen med least privilege, sandboxing og brugerbekræftelse ved følsomme handlinger begrænser det konsekvensen, selv hvis selve modellen kan påvirkes. (Beurer-Kellner et al., 2025)

6. Den røde tråd: en samlet risikokæde

De tre problemområder kan samles i den risikokæde, som opgaveoplægget beskriver: ambiguous prompts -> ambiguous responses -> user misinterpretation -> hallucinated or incorrect beliefs -> manipulation opportunities -> societal impact. Kæden skal ikke forstås som, at hvert led altid fører til det næste. Den fungerer som en analytisk model for, hvordan små problemer i interaktionen kan vokse, når output genbruges, automatiseres eller får større organisatorisk betydning.

Led	Eksempel	Mulig konsekvens
1. Ambiguity	Et krav eller spørgsmål mangler centrale detaljer.	Modellen antager intentionen.
2. Semantic drift	Svaret omskrives eller opsummeres over flere led.	Formål eller kontekst forskydes.
3. Hallucination	Modellen udfylder et videnshul med plausibelt indhold.	Forkert information accepteres eller genbruges.
4. Prompt injection	En angriber indsætter instruktioner i input eller eksterne data.	Systemet manipuleres eller forsøger uautoriserede handlinger.
5. Organisatorisk effekt	Outputtet bruges i beslutning, kommunikation eller agent-workflow.	Tillid, kvalitet eller sikkerhed påvirkes.

Set fra virksomhedens perspektiv rammer problemstillingerne forskellige ledelsesområder. For en CEO handler de om kvalitet, tillid og beslutningsgrundlag. For en CSO handler de især om trust boundaries, adgang til værktøjer og prompt injection. For en CHRO handler de om kompetencer, procedurer og at medarbejdere forstår, hvornår et AI-output kræver kontrol. Det fælles punkt er, at LLM-risiko ikke kun er et modelproblem, men et samspil mellem model, bruger og systemdesign.

7. anbefalinger til organisationer

Reducer underspecificering. Gør opgave, kontekst, begrænsninger og ønsket output 24eksplcit. Systemer bør bede om afklaring, når manglende information er kritisk.

Bevar oprindelig intention. Ved omskrivning og opsummering bør formål, målgruppe og centrale forbehold fastholdes og kontrolleres - ikke kun fakta.

Ground vigtige svar. Brug verificerbare kilder eller RAG, når output afhænger af konkret viden, og kræv kontrol af påstande med høj konsekvens.

Accepter usikkerhed. Et sikkert system bør kunne afstå fra at svare frem for at udfylde et videnshul med en plausibel fabrikation.

Behandl eksternt indhold som untrusted. Dokumenter, websider og brugertekst kan indeholde instruktioner. De bør ikke automatisk kunne styre agentens handlinger.

Begræns agents rettigheder. Brug least privilege, application-specific actions, isolation/sandboxing og human confirmation ved følsomme handlinger.

Brug flere lag af forsvar. Ingen enkelt prompt, detector eller filter bør betragtes som tilstrækkelig. Sikkerhed bør bygges i hele arkitekturen.

(Bang et al., 2025; Beurer-Kellner et al., 2025; Zhang, Wang & Meng, 2026)

8. Konklusion

Litteraturen viser, at pålidelighed i LLM-baserede systemer kan bryde sammen på flere niveauer. Ambiguity kan få modellen til at antage en forkert intention, og multi-turn samtaler kan gøre det svært at rette en tidlig fejl. Semantic drift kan ændre formålet med information, selv når de overfladiske fakta bevares. Hallucination kan skabe ikke-understøttet indhold, som fremstår troværdigt, mens prompt injection kan udnytte samme instruction-following-mekanisme bevidst.

Den vigtigste samlede pointe er derfor, at bedre prompting alene ikke løser problemet. Troværdige LLM-systemer kræver en kombination af tydelig kommunikation, grounding og verifikation, mulighed for at afstå fra svar, sikre trust boundaries og begrænsede agent-rettigheder. Jo mere autonomi og adgang et LLM-system får, desto vigtigere bliver systemdesign og menneskelig kontrol. LLM'en kan støtte en beslutning, men organisationen må stadig eje ansvaret for beslutningen og konsekvensen.

(Laban et al., 2025; Maxwell, u.å.; Bang et al., 2025; Zhang, Wang & Meng, 2026; Jaiswal et al., 2026; Beurer-Kellner et al., 2025)

Litteratur

Bang, Y., Ji, Z., Schelten, A., Hartshorn, A., Fowler, T., Zhang, C., Cancedda, N. & Fung, P. (2025). HalluLens: LLM Hallucination Benchmark. arXiv:2504.17550.

Beurer-Kellner, L., Buesser, B., Cretu, A.-M., Debenedetti, E., Dobos, D., Fabian, D., Fischer, M., Froelicher, D., Grosse, K., Naeff, D., Ozoani, E., Paverd, A., Tramer, F. & Volhejn, V. (2025). Design Patterns for Securing LLM Agents against Prompt Injections. arXiv:2506.08837.

Jaiswal, P., Pratap, A., Saraswati, S., Kasyap, H. & Tripathy, S. (2026). Analysis of LLMs Against Prompt Injection and Jailbreak Attacks. LM-SHIELD '26, ACM. DOI: 10.1145/3803628.3807972.

Laban, P., Hayashi, H., Zhou, Y. & Neville, J. (2025). LLMs Get Lost in Multi-Turn Conversation. arXiv:2505.06120.

Maxwell, I. A. (u.å.). The Half-Life of Truth: Semantic Drift vs Factual Degradation in Recursive Large Language Model Generation.

Zhang, C., Wang, H. & Meng, H. (2026). Hallucination Detection and Evaluation of Large Language Model. arXiv:2512.22416v2.